

Capítulo 9

Análisis de series temporales

La mayoría de los métodos descritos hasta ahora en este libro están orientados principalmente al análisis transversal, o al estudio de una muestra de datos tomados en el mismo momento. En este capítulo, pasamos a los métodos para modelar una serie de tiempo o una variable que se observa secuencialmente a intervalos regulares a lo largo del tiempo (por ejemplo, diaria, semanal, mensual, trimestral o anual). Los datos de series de tiempo con frecuencia tienen tendencias y procesos de error complejos, por lo que no tener en cuenta estas características puede producir resultados falsos (Granger y Newbold 1974). Han surgido varios enfoques para el análisis de series de tiempo para abordar estos problemas y prevenir inferencias falsas. Dentro de la ciencia política, los estudiosos de la opinión pública, la economía política, los conflictos internacionales y varios otros temas trabajan regularmente con datos referenciados en el tiempo, por lo que las herramientas adecuadas para el análisis de series de tiempo son importantes en el análisis político.

Muchos investigadores no piensan en R como un programa para el análisis de series de tiempo, en lugar de utilizar software especializado como Autobox, EViews o RATS. Incluso SAS y Stata tienden a recibir más atención para el análisis de series de tiempo que R lo hace. Sin embargo, R en realidad tiene una amplia gama de comandos para modelos de series de tiempo, particularmente a través del TSA y vars paquetes. En este capítulo, ilustraremos tres enfoques para el análisis de series de tiempo en R: el enfoque de Box-Jenkins, extensiones a modelos lineales estimados con mínimos cuadrados y autorregresión vectorial. Esta no es una lista exhaustiva de las herramientas disponibles para estudiar series de tiempo, pero solo pretende presentar algunos métodos destacados. Ver secc. 9.4 para leer más sobre series de tiempo.

Tanto el enfoque de Box-Jenkins como las extensiones de los modelos lineales son ejemplos de modelos de series de tiempo de una sola ecuación. Ambos enfoques tratan una serie de tiempo como una variable de resultado y se ajustan a un modelo de ese resultado que se puede establecer en una ecuación, al igual que los modelos de regresión de los capítulos anteriores se pueden enunciar en una sola ecuación. Dado que ambos enfoques caen en esta categoría amplia, el trabajo

Electrónico suplementario material: La en línea versión de este capítulo (doi: [10.1007/978-3-319-23446-5_9](https://doi.org/10.1007/978-3-319-23446-5_9)) contiene usuarios autorizados material, que está disponible para suplementarios.

El conjunto de datos que usamos para el enfoque de Box-Jenkins y las extensiones de los modelos lineales serán de Peake y Eshbaugh-Soha (2008) datos mensuales sobre la cobertura televisiva de la política energética que se introdujo por primera vez en el Cap. 3. Por el contrario, la autorregresión vectorial es un modelo de series de tiempo de ecuaciones múltiples (para obtener más detalles sobre esta distinción, consulte Brandt y Williams 2007 o Lütkepohl 2005). Con un modelo de autorregresión vectorial, dos o más series de tiempo se consideran endógenas, por lo que se requieren múltiples ecuaciones para especificar completamente el modelo. Esto es importante porque las variables endógenas pueden afectarse entre sí y, para interpretar el efecto de una variable de entrada, se debe considerar el contexto más amplio del sistema completo. Dado que los modelos de ecuaciones múltiples tienen una especificación tan diferente, al discutir la autorregresión vectorial, el ejemplo de trabajo será Brandt y Freeman (2006) análisis de las acciones políticas semanales en el conflicto israelo-palestino; Se plantearán más detalles una vez que lleguemos a esa sección.

9.1 El método Box-Jenkins

El enfoque de Box-Jenkins para las series de tiempo se basa en modelos de promedio móvil integrado autorregresivo (ARIMA) para capturar el proceso de error en los datos. Para obtener una explicación completa de este enfoque, consulte Box et al. (2008). La lógica básica de este enfoque es que una serie de tiempo debe filtrarse, *opreblanqueado* de cualquier tendencia y proceso de error antes de intentar ajustar un modelo inferencial. Una vez que un modelo de *laruido*, o error, se ha especificado, entonces el investigador puede proceder a probar hipótesis.¹ Debido a las formas funcionales no lineales que a menudo surgen en ARIMA y en los modelos de función de transferencia, estas generalmente se estiman con la máxima probabilidad.

Para ilustrar el proceso desde la identificación de un modelo de error hasta la prueba de una hipótesis, revisamos la de Peake y Eshbaugh-Soha (2008) Serie temporal mensual sobre cobertura de pólizas energéticas. Comenzamos recargando nuestros datos:²

```
pres.energy <- read.csv ("PESenergy.csv")
```

Nuestra variable de resultado es el número de historias relacionadas con la energía en los noticieros de televisión nocturnos por mes (**Energía**). Un buen primer paso es trazar la serie que se está estudiando para ver si alguna tendencia u otras características son evidentes de inmediato. Vuelva a mirar la Fig. 3.6 para el código de ejemplo que usamos para trazar nuestra variable de resultado (**Energía**) y el precio del petróleo, que es uno de los predictores (**aceitec**). Como primer vistazo a la serie de cobertura de noticias, los datos parecen ser *estacionario*, lo que significa que se ciernen alrededor de un medio sin *tendencias* en una dirección o mostrando un *integrado* patrón.

Como punto sustancialmente importante sobre las series de tiempo en general, la distinción entre *estacionario* y *no estacionario* la serie es importante. Muchos métodos de series de tiempo

¹Muchos usan modelos ARIMA para pronosticar valores futuros de una serie. Los modelos ARIMA en sí mismos son ateóricos, pero a menudo pueden ser efectivos para la predicción. Dado que la mayor parte del trabajo de ciencia política implica probar hipótesis motivadas teóricamente, esta sección se centra más en el papel que los modelos ARIMA pueden servir para establecer modelos inferenciales.

²Si no tiene el archivo de datos PESenergy.csv Ya puede descargarlo del Dataverse (consulte la página vii) o del contenido del capítulo en línea (consulte la página 155).

están diseñados específicamente para modelar series estacionarias, por lo que su aplicación a una serie no estacionaria puede resultar problemático. *A estacionario* La serie es aquella para la que la media y la varianza no cambian condicionalmente en el tiempo, y la serie no tiene una tendencia en una dirección. Si una serie estacionaria se altera o se mueve a un valor más alto o más bajo, eventualmente regresa a un nivel de equilibrio. Los dos tipos de *no estacionario* Las series son series de tendencia y series integradas. Con un *tendencias* serie, como su nombre lo indica, el promedio condicional cambia con el tiempo, por lo general subiendo o bajando de manera constante. Por ejemplo, los precios nominales de los bienes de consumo pueden subir o bajar de un trimestre a otro, pero el valor medio tiende a subir con el tiempo. Un *serie integrada*, también llamada serie de raíz unitaria, no tiene un valor de equilibrio y tiene la característica de "memoria larga". Esto significa que si algo cambia el valor de una serie, los valores futuros de la serie se verán afectados por ese cambio en el futuro. Por ejemplo, supongamos que el promedio industrial Dow Jones cayó 300 puntos en un día, de 18.200 a 17.900. En tal caso, los valores futuros del Dow se basarán en el nuevo valor de 17,900 más cuánto subió o bajó el valor cada día subsiguiente, y el Dow no tenderá a volver a los valores anteriores. Es importante destacar que por *diferenciando* el valor actual de una serie a partir de su valor anterior, o midiendo cuánto cambió una serie de una vez a la siguiente, las series integradas o en tendencia se pueden hacer estacionarias. Por lo tanto, se pueden aplicar muchos modelos para series estacionarias a la diferencia de una serie no estacionaria. Siempre que realice un trabajo de series de tiempo aplicadas, observe siempre el gráfico de la serie, como la Fig.3.6 en este caso, así como los diagnósticos que se describirán para determinar si está estudiando una serie estacionaria, de tendencia o de raíz unitaria.³

Como segundo paso, pasamos a las medidas de diagnóstico y observamos el autoCorrelación Función (ACF) y pagartial autoCorrelación Función (PACF). La función de autocorrelación muestra cuánto se correlacionan los valores actuales de una serie con los valores anteriores en un cierto *retraso*. *Retrasos* son importantes para el modelado de series de tiempo, como se verá más adelante en el capítulo, y actúan cambiando el índice de una serie para hacer retroceder el tiempo y formar una nueva serie. Por ejemplo, un desfase de primer orden es una nueva serie donde cada observación es el valor que ocurrió un período de tiempo anteriormente. Un retraso de segundo orden es una nueva serie en la que cada observación es el valor de dos períodos de tiempo anteriores, y así sucesivamente. Esto es importante cuando se usa la función de autocorrelación porque, si estamos estudiando una serie con índice de tiempo t , ACF (1) nos daría la correlación entre y_t y y_{t-1} . (Entonces, para la cobertura de energía, ACF (1) nos dice la correlación entre la cobertura de los meses actuales y la cobertura de los meses anteriores). Posteriormente, ACF (2) sería la autocorrelación entre y_t y y_{t-2} , y más generalmente ACF (p) es la autocorrelación entre y_t y y_{t-p} . El PACF proporciona la autocorrelación entre los valores actuales y retrasados *que no es contabilizado por todos retrasos previos*. Entonces, para el primer rezago, ACF (1) = PACF (1), pero para todos los rezagos posteriores, solo la autocorrelación única de ese retraso aparece en el PACF. Si quisiéramos conocer los ACF y PACF de nuestra serie de políticas energéticas, escribiríamos:

³Además de examinar la serie original o la función de autocorrelación, una prueba de Dickey-Fuller aumentada también sirve para diagnosticar si una serie de tiempo tiene una raíz unitaria. Al cargar el `tseries` paquete, el comando `adf.test` realizará esta prueba en R.

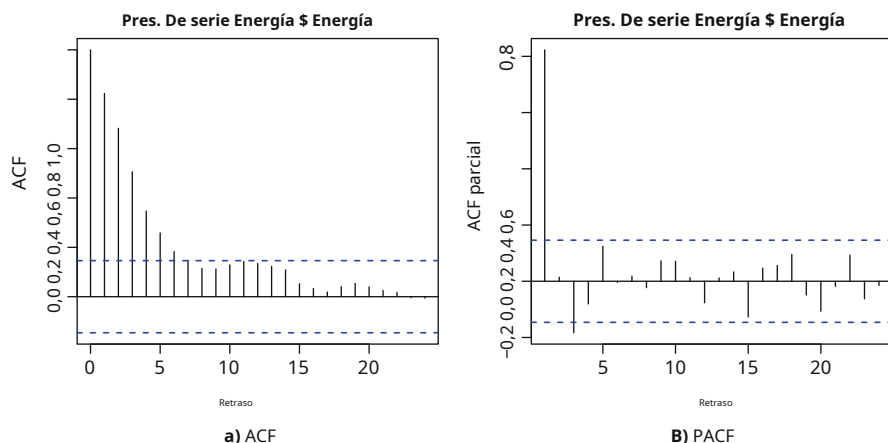


Figura 9.1 Función de autocorrelación y función de autocorrelación parcial de la cobertura televisiva mensual de la política energética a través de 24 rezagos. (a) ACF. (b) PACF

```
acf(pres.energy $ Energy, lag.max = 24) pacf(
pres.energy $ Energy, lag.max = 24)
```

La `acf` y `pacf` Las funciones están disponibles sin cargar un paquete, aunque el código cambia ligeramente si los usuarios cargan el TSA paquete.⁴ Observe que dentro del `acf` y `pacf` funciones, primero enumeramos las series que estamos diagnosticando. En segundo lugar, designamos `lag.max`, que es el número de rezagos de autocorrelación que deseamos considerar. Dado que estos son datos mensuales, 24 rezagos nos dan 2 años de rezagos. En algunas series, *estacionalidad* emergerá, en el que vemos evidencia de valores similares en la misma época cada año. Esto se vería con rezagos significativos alrededor de 12 y 24 con datos mensuales (o alrededor de 4, 8 y 12, por el contrario, con datos trimestrales). No aparece tal evidencia en este caso.

Los gráficos de nuestro ACF y PACF se muestran en la Fig. 9.1. En cada uno de estos En las cifras, el eje horizontal representa la longitud del retardo y el eje vertical representa el valor de correlación (o correlación parcial). En cada retraso, la autocorrelación para ese retraso se muestra con una línea sólida similar a un histograma desde cero hasta el valor de la correlación. Las líneas discontinuas azules representan el umbral para una correlación significativa. Específicamente, las bandas azules representan el intervalo de confianza del 95% basado en una serie no correlacionada.⁵ Todo esto significa que si la línea similar a un histograma no

⁴El principal cambio notable es que la versión predeterminada de `acf` grafica la correlación de retardo cero, ACF (0), que siempre es 1.0. La TSA La versión elimina esto y comienza con la primera autocorrelación de retardo, ACF (1).

⁵La fórmula para estas bandas de error es: $0.1:96 \text{ se}$. El error estándar para un coeficiente de correlación

es: $\text{se}_r D q \frac{1}{n}$. Entonces, en este caso, establecemos $r D 0$ bajo la hipótesis nula, y n es el tamaño de la muestra (o longitud de la serie).

Si se cruza la línea discontinua, el nivel de autocorrelación no es perceptiblemente diferente de cero, pero los picos de correlación fuera de la banda de error son estadísticamente significativos.

El ACF, en la Fig. 9.1a comienza mostrando la autocorrelación de retardo cero, que es la cantidad de valores actuales que se correlacionan consigo mismos, siempre exactamente 1.0. Luego, vemos los valores más informativos de autocorrelación en cada rezago. Con un retraso, por ejemplo, la correlación en serie es 0,823. Para dos rezagos, cae a 0.682. El sexto retraso es el último retraso en mostrar una autocorrelación discernible, por lo que podemos decir que el ACF decae rápidamente. El PACF, en la Fig.9.1b, omite el retardo cero y comienza con la correlación serial de primer orden. Como se esperaba, esto es 0.823, tal como mostró el ACF. Sin embargo, una vez que damos cuenta de la correlación serial de primer orden, los términos de autocorrelación parcial en rezagos posteriores no son estadísticamente discernibles.⁶

En este punto, determinamos qué proceso de error ARIMA dejaría una huella empírica como la que muestran este ACF y PACF. Para obtener más detalles sobre las huellas comunes, consulte Enders (2009, pag. 68). Notablemente, llamamos al proceso de error ARIMA (p, d, q), donde p es el número de términos autorregresivos, d es cuántas veces se debe diferenciar la serie, y q es el número de términos de media móvil. Funcionalmente, un general ARMA modelo, que incluye autorregresivo y en movimiento componentes promedio, se escribe de la siguiente manera:

$$y_t D_{,0} C_{pag} \overset{X}{ID1} + \sum_{i=1}^q y_{t-i} C_{it} \overset{X^q}{ID1} + \epsilon_t C_t \quad (9,1)$$

Aquí, y_t es nuestra serie de interés, y este modelo ARMA se convierte en un ARIMA modelo cuando decidimos si necesitamos diferenciar y_t o no. Darse cuenta de y_t está rezagado pag tiempos para los términos autorregresivos, y el término de perturbación (ϵ_t) está rezagado q tiempos para los términos de la media móvil. En el caso de la cobertura de la póliza energética, la ACF muestra un rápido decaimiento y vemos un pico significativo en el PACF, por lo que podemos decir que estamos tratando con un proceso autorregresivo de primer orden, denotado AR (1) o ARIMA (1,0,0).

Una vez que hemos identificado nuestro autoragresivo integrado metrooving a modelo promedio, podemos estimarlo usando el arima función:

```
ar1.mod <- arima (pres.energy $ Energy, order = c (1,0,0))
```

La primera entrada es la serie que estamos modelando y la pedido opción nos permite especificar p , d y q (en orden) para nuestro ARIMA (p, d, q) proceso. Escribiendo `ar1.mod`, vemos la salida de nuestros resultados:

Llamada:

```
arima (x = energía pres. $ Energía, orden = c (1, 0, 0))
```

Coefficientes:

	ar1	interceptar
	0.8235	32.9020
se	0.0416	9.2403

⁶Técnicamente, PACF en el tercer rezago es negativo y significativo, pero los patrones comunes de error Los procesos sugieren que es poco probable que esto sea una parte crítica del proceso ARIMA.

σ^2 estimado como 502.7: probabilidad logarítmica = -815.77, aic = 1637.55

Simplemente, esto nos muestra la estimación y el error estándar del coeficiente autorregresivo (ar1) e interceptar, así como la varianza residual, la probabilidad logarítmica y el AIC.

El siguiente paso en el proceso de modelado de Box-Jenkins es diagnosticar si el modelo estimado filtra suficientemente los datos.⁷ Hacemos esto de dos maneras: Primero, estudiando el ACF y PACF para los residuos del modelo ARIMA. El código es:

```
acf(ar1.mod$residuales, lag.max = 24) pacf
(ar1.mod$residuales, lag.max = 24)
```

Al igual que con muchos otros modelos, podemos llamar a nuestros residuos usando el nombre del modelo y un signo de dólar (ar1.mod\$residuales). Los gráficos resultantes se presentan en la Fig. 9.2. Como muestran tanto el ACF como el PACF, el segundo y el cuarto rezagos apenas cruzan el umbral de significancia, pero no hay un patrón claro o evidencia de una característica pasada por alto del proceso de error. La mayoría (pero no todos) los analistas se contentarían con este patrón en estas cifras.

Como segundo paso para diagnosticar si hemos filtrado suficientemente los datos, calculamos el **Ljung-Caja Q-prueba**. Esta es una prueba conjunta de varios rezagos para determinar si existe evidencia de correlación serial en alguno de los rezagos. La hipótesis nula es que

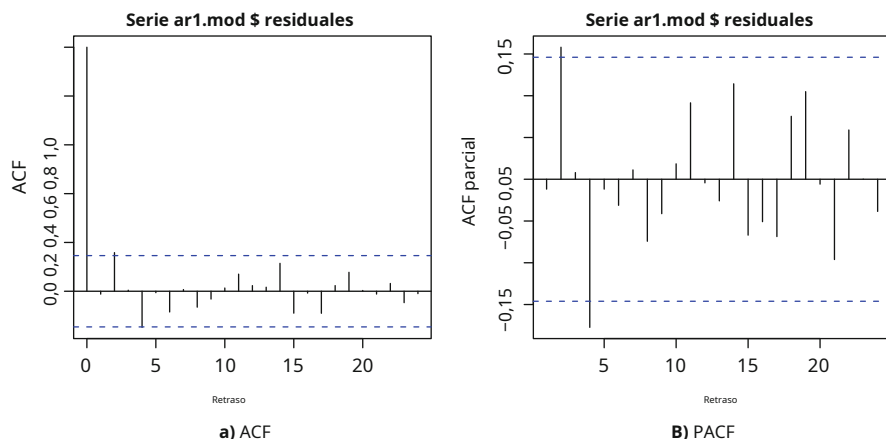


Figura 9.2 Función de autocorrelación y función de autocorrelación parcial para residuos de AR (1) modelo a través de 24 rezagos. Líneas discontinuas azules representan un intervalo de confianza del 95% para una serie no correlacionada. (a) ACF. (b) PACF (figura de color en línea)

⁷Aquí mostramos en el texto principal cómo recopilar un diagnóstico a la vez, pero el lector también puede querer intentar escribir `tsdiag(ar1.mod, 24)` para recopilar representaciones gráficas de algunos diagnósticos a la vez.

los datos son independientes, por lo que un resultado significativo sirve como evidencia de un problema. La sintaxis de esta prueba es:

```
Box.test(ar1.mod $ residuals, lag = 24, type = "Ljung-Box")
```

Primero especificamos la serie de interés, luego con el retraso la opción indica cuántos retrasos deben entrar en la prueba y, por último, con tipo especificar Ljung-Box (a diferencia de la prueba Box-Pierce, que no funciona tan bien). Nuestros resultados de esta prueba son:

Prueba de Box-Ljung

datos: ar1.mod \$ residuales

X al cuadrado = 20,1121, gl = 24, valor p = 0,6904

Nuestra estadística de prueba no es significativa (*pag* D 0: 6904), por lo que esta prueba no muestra evidencia de correlación serial durante los retrasos de 2 años. Si estamos satisfechos de que AR (1) caracteriza nuestro proceso de error, podemos proceder al modelado real en la siguiente sección.

9.1.1 Funciones de transferencia frente a modelos estáticos

Para estimar un modelo teóricamente motivado, necesitamos establecer una distinción importante entre dos tipos de formas funcionales: por un lado, una *estático* La forma funcional asume que los valores actuales de los predictores afectan los valores actuales de los resultados. Por ejemplo, podemos creer que el precio del petróleo en un mes determinado afecta la cobertura de temas energéticos en la televisión en el mismo mes, mientras que los precios del petróleo del próximo mes afectarán la cobertura energética del próximo mes. Si pensamos que este es el único proceso en curso, entonces queremos una forma funcional estática. Por otro lado, podemos utilizar una *dinámica* forma funcional. En el caso de los precios del petróleo, esto significaría que los precios del petróleo de este mes afectarían la cobertura energética de este mes, y también la cobertura del mes siguiente en menor grado, el mes siguiente en menor grado aún, y así sucesivamente. Esencialmente, una forma funcional dinámica permite efectos secundarios de cada observación de una entrada.

La estimación de un modelo de regresión estática con un proceso de error ARIMA solo requiere dos pasos en R. Primero, todas las variables predictoras deben colocarse en una matriz. En segundo lugar, simplemente podemos agregar una opción a nuestra *arima* función:

```
predictores <- as.matrix(subconjunto(pres.energy, select = c(rmn1173,
  grf0175, grf575, jec477, jec1177, jec479, embargo, rehenes, oilc, aprobación,
  desempleo)))
static.mod <- arima(pres.energy $ Energy, order = c(1,0,0),
  xreg = predictores)
```

En este código, primero subconjunto nuestro conjunto de datos original y tratamos el subconjunto **como a matriz** llamado predictores. En segundo lugar, usamos el mismo *arima* funciona como usamos para estimar nuestro modelo de ruido AR (1), pero agregue la opción `xreg = predictores`. Esto ahora estima un modelo en el que se corrige el proceso de error temporal, pero también incluimos predictores de interés motivados teóricamente. Si escribimos `static.mod`, la salida es:

Llamada:

arima (x = energía pres. \$ Energía, orden = c (1,0,0), xreg = predictores)

Coefficientes:

	ar1	interceptar	rmn1173	grf0175	grf575
	0.8222	5.8822	91.3265	31.8761	- 8.2280
se	0.0481	52.9008	15.0884	15.4643	15.2025
	jec477	jec1177	jec479	embargo	rehenes
	29.6446	- 6.6967	-20.1624	35.3247	- 16.5001
se	15.0831	15.0844	15.2238	15.1200	13.7619
	oilc	Aprobación Desempleo			
	0.8855	- 0,2479	1,0080		
se	1.0192	0,2816	3,8909		

σ^2 estimado como 379,3: probabilidad logarítmica = -790,42, aic = 1608,84

Esto ahora nos muestra la estimación y el error estándar no solo para el coeficiente autorregresivo y la intersección, sino también para el coeficiente de regresión parcial de todos los demás predictores del modelo. Nuevamente, las tres medidas de ajuste se informan al final de la impresión.

Si quisiéramos incluir uno o más predictores que tengan un efecto dinámico, entonces recurrimos al método de *funciones de transferencia*, que especifican que un predictor tiene un efecto de desbordamiento en las observaciones posteriores. Un caso especial de esto se llama *análisis de intervención*, en el que un tratamiento se codifica con un indicador (Box y Tiao 1975). Con el análisis de la intervención, pueden surgir una variedad de formas funcionales, dependiendo en gran medida de si la variable indicadora está codificada como *pulso* (tomando un valor de 1 solo en el momento del tratamiento, y 0 en caso contrario) o un *paso* (tomando un valor de 0 antes del tratamiento y de 1 en todos los momentos posteriores). Es recomendable probar ambas codificaciones y leer más en la forma funcional de cada una (Enders 2009, Secta. 5.1).

Como ilustración, ajustamos una función de transferencia para una intervención de pulso para el discurso de Richard Nixon en noviembre de 1973. Para estimar este modelo, ahora necesitamos cargar el TSA paquete para acceder al arimax función (**ARIMA** con **X** predictores). Recuerde que es posible que deba usar `install.packages` descargar TSA:

```

biblioteca install.packages
("TSA") (TSA)
dynamic.mod <-arimax (pres.energy $ Energy, order = c (1,0,0),
  xreg = predictores [, - 1], xtransf = predictores [, 1],
  transferencia = lista (c (1,0)))

```

La sintaxis de arimax es parecido a arima, pero ahora se nos permiten algunas opciones más para las funciones de transferencia. Note en este caso que usamos el código `xreg = predictores [-1]` para eliminar el indicador del discurso de Nixon de noviembre de 1973 de los predictores estáticos. En su lugar, colocamos este predictor con `elxtransf` opción. Lo último que debemos hacer es especificar el orden de nuestra función de transferencia, lo que hacemos con la opción `transferir`. La `transferir` opción acepta una lista de

vectores, un vector por predictor de función de transferencia. Para nuestra única función de transferencia, especificamos $(1,0)$: El primer término se refiere al orden del término de desintegración dinámica (por lo que un 0 aquí en realidad se revierte a un modelo estático), y el segundo término se refiere a la duración del retardo del efecto del predictor (por lo tanto, si esperaríamos que un efecto fuera *crecer*, podríamos poner un número mayor que 0 aquí). Con estos ajustes, decimos que el discurso de Nixon tuvo un efecto en el mes que lo pronunció, y luego el efecto se extendió a los meses siguientes a un ritmo decreciente.

Escribiendo `dynamic.mod`, obtenemos nuestra salida:

Llamada:

```
arimax(x = pres.energy $ Energy, order = c(1,0,0), xreg =
predictores[, - 1],
xtransf = predictores[, 1], transferencia = lista(c(1, 0)))
```

Coefficientes:

	ar1	interceptar	grf0175	grf575	jec477
	0.8262	20.2787	31.5282	- 7.9725	29.9820
se	0.0476	46.6870	13.8530	13.6104	13.5013
	jec1177	jec479	embargo	rehenes	oilc
	- 6.3304	- 19.8179	25.9388	- 16.9015	0.5927
se	13.5011	13.6345	13.2305	12.4422	0.9205
	Aprobación	Desempleo	T1-AR1	T1-MA0	
	- 0.2074	0.1660	0.6087	160.6241	
se	0.2495	3.5472	0.0230	17.0388	

σ^2 estimado como 305,1: probabilidad logarítmica = -770,83, aic = 1569,66

El resultado es similar al del modelo de regresión ARIMA estático, pero ahora hay dos términos para el efecto del habla de Nixon. El primero, T1-AR1, da el término de desintegración. Cuanto más cercano esté este término a 1, más persistente será el efecto de la variable. El segundo término, T1-MA0, es el efecto inicial del discurso sobre la cobertura energética en el mes en que se impartió.⁸ En términos de ajuste del modelo, observe que la salida de cada ARIMA o modelo de función de transferencia que hemos estimado informa el criterio de información de Akaike (AIC). Con esta medida, las puntuaciones más bajas indican un ajuste mejor penalizado. Con una puntuación de 1569,66, este modelo de función de transferencia dinámica tiene el AIC más bajo de todos los modelos.

⁸En este caso, tenemos una entrada de pulso, por lo que podemos decir que en noviembre de 1973, el efecto del discurso fue un aumento esperado de 161 noticias, manteniendo todo lo demás igual. En diciembre de 1973, el efecto de arrastre es que esperamos 98 historias más, manteniendo todo lo demás igual porque 161 0:61

98.

En enero de 1974, el efecto de la intervención es que esperamos 60 historias más, *ceteris paribus* porque 161 0:61 0:61 60. El efecto de la intervención continúa avanzando en una decadencia similar.

patrón. Por el contrario, si habíamos obtenido estos resultados con un *paso* intervención en lugar de una *legumbres* intervención, entonces estos efectos se acumularían en lugar de decaer. Bajo este hipotético, los efectos serían 161 en noviembre de 1973, 259 en diciembre de 1973 (porque $161 + 98 = 259$) y 319 en enero de 1974 (porque $161 + 98 + 60 = 319$).

nos hemos ajustado a estos datos. Por lo tanto, el modelo dinámico tiene un mejor ajuste que el modelo estático o el modelo ateórico AR (1) sin predictores.

Sin embargo, para tener una idea real del efecto de un análisis de intervención, un analista siempre debe intentar dibujar el efecto que modeló. (Nuevamente, es clave estudiar la forma funcional detrás de la especificación de intervención elegida, como lo describe Enders²⁰⁰⁹, Secta. 5.1.) Para dibujar el efecto de nuestra intervención para el discurso de Nixon de 1973, escribimos:

```
meses <- c (1: 180)
y.pred <- dynamic.mod $ coef [2:12] % *% c (1, predictores [58, -1]) +
  160.6241 * predictores [, 1] +
  160.6241 * (. 6087 ^ (meses-59)) * como numérico (meses> 59)
plot (y = energía pres. $ Energía, x = meses, xlab = "Mes",
      ylab = "Energy Policy Stories", type = "l", axes = F) axis (1, at = c
(1,37,73,109,145), labels = c ("Jan. 1969",
"ENE. 1972", "ENE. 1975", "ENE. 1978", "ENE. 1981")) eje (2)

caja()
líneas (y = y.pred, x = meses, lty = 2, col = "blue", lwd = 2)
```

En la primera línea, simplemente creamos un índice de tiempo para los 180 meses del estudio. En la segunda línea, creamos valores predichos para el efecto de la intervención manteniendo todo lo demás igual. Una suposición crítica que hacemos es que mantenemos todos los demás predictores iguales al establecerlos en sus valores de octubre de 1973, el mes 58 de la serie (por lo tanto, predictores [58, -1]). Entonces, considerando los componentes de esta segunda línea, el primer término multiplica los coeficientes de los predictores estáticos por sus últimos valores antes de la intervención, el segundo término captura el efecto de la intervención en el mes del discurso y el tercer término captura el desbordamiento. efecto de la intervención en función del número de meses transcurridos desde el discurso. Las siguientes cuatro líneas simplemente dibujan un gráfico de los valores de nuestra serie original y administran algunas de las características del gráfico. Por último, agregamos una línea discontinua que muestra el efecto de la intervención manteniendo constante todo lo demás. El resultado se muestra en la figura.9.3. Como muestra la figura, el resultado de esta intervención es un salto grande y positivo en el número esperado de noticias, que se prolonga durante unos meses, pero finalmente regresa a los niveles previos a la intervención. Este tipo de gráfico es esencial para comprender cómo la intervención dinámica afecta realmente al modelo.

Como gráfico final para complementar nuestra visión del efecto de la intervención dinámica, podríamos dibujar un gráfico que muestre qué tan bien se alinean las predicciones del modelo completo con los valores reales de la serie. Podríamos hacer esto con el siguiente código:

```
meses <- c (1: 180)
full.pred <- pres.energy $ Energy-dynamic.mod $ residuals plot (y =
full.pred, x = months, xlab = "Month",
      ylab = "Energy Policy Stories", type = "l", ylim = c
(0,225), axes = F)
puntos (y = energía pres. $ Energía, x = meses, pch = 20) leyenda
(x = 0, y = 200, leyenda = c ("Predecir", "Verdadero"),
      pch = c (NA, 20), lty = c (1, NA)) eje (1, at = c (1,37,73,109,145),
labels = c ("Enero de 1969",
"ENE. 1972", "ENE. 1975", "ENE. 1978", "ENE. 1981")) eje (2)

caja()
```




Figura 9.3 La *línea discontinua* muestra el efecto dinámico del discurso de Nixon de noviembre de 1973, manteniendo todo lo demás igual. La *línea sólida* muestra los valores observados de la serie

Nuevamente, comenzamos creando un índice de tiempo, meses. En la segunda línea, creamos nuestros valores predichos restando los residuos de los valores verdaderos. En la tercera línea de código, dibujamos un gráfico lineal de los valores predichos del modelo. En la cuarta línea, agregamos puntos que muestran los valores reales de la serie observada. Las líneas restantes completan el formato del gráfico. El gráfico resultante se muestra en la Fig.9.4. Como puede verse, el ajuste en la muestra es bueno, con los valores predichos siguiendo de cerca los valores verdaderos.

Como punto final aquí, se anima al lector a consultar el código en la Sect. 9.5 para una sintaxis alternativa para producir las Figs. 9.3 y 9.4. La compensación de la forma alternativa de dibujar estas cifras es que requiere más líneas de código por un lado, pero por otro lado, es más generalizable y más fácil de aplicar a su propia investigación. Además, el código alternativo presenta cómo El comando permite a los analistas convertir una variable en un *objeto de serie temporal*. Vale la pena ver ambos enfoques para ilustrar que, en general, muchas tareas se pueden realizar de muchas formas en R.

9.2 Extensiones a modelos de regresión lineal por mínimos cuadrados

Un segundo enfoque para el análisis de series de tiempo se basa más en la literatura econométrica y busca formas de extender los modelos de regresión lineal para tener en cuenta los problemas únicos asociados con los datos referenciados en el tiempo. Dado que ya discutimos ampliamente la visualización con estos datos en la Sect.9.1, no revisaremos los problemas de gráficos aquí. Sin embargo, al igual que con los modelos de tipo Box-Jenkins, el analista siempre debe

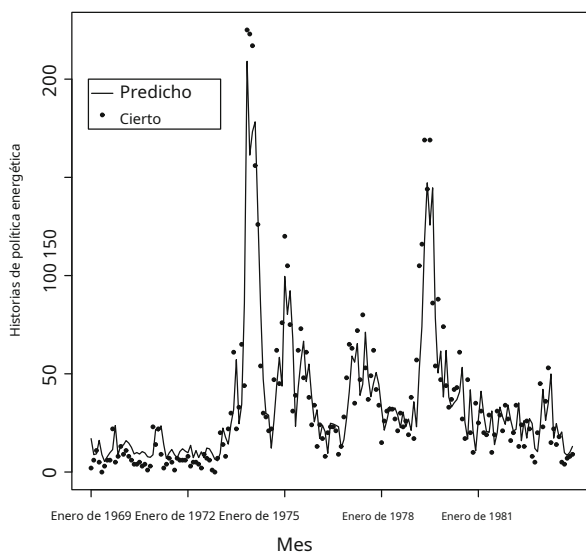


Figura 9.4 Valores predichos de un modelo de función de transferencia completa — una línea, con valores reales observados en puntos

Empiece por dibujar un diagrama de líneas de la serie de interés y, idealmente, también algunos predictores clave. Incluso los gráficos de diagnóstico como el ACF y PACF serían apropiados, además de los diagnósticos residuales como los que discutiremos en breve.

Al modelar datos desde un enfoque econométrico, los investigadores nuevamente tienen que decidir si usar una especificación estática o dinámica del modelo. Para los modelos estáticos en los que los valores actuales de los predictores afectan los valores actuales del resultado, los investigadores pueden estimar el modelo con mínimos cuadrados ordinarios (MCO) en el *raro* caso de no correlación serial. Sin embargo, para las ganancias de eficiencia en un modelo estático, los mínimos cuadrados generalizados factibles (FGLS) son un mejor estimador. Por el contrario, en el caso de una forma funcional dinámica, se puede introducir una estructura rezagada en la especificación del modelo lineal.

Comenzando con modelos estáticos, el tipo de modelo más simple (aunque raramente apropiado) sería estimar el modelo usando MCO simple. Volviendo a los datos de nuestra política energética, la especificación de nuestro modelo aquí sería:

```
static.ols <-lm (Energía ~ rmn1173 + grf0175 + grf575 + jec477 +
                jec1177 + jec479 + embargo + rehenes + petróleooc +
                Aprobación + Desempleo, datos = energía pres.)
```

Escribiendo `resumen(static.ols)` obtenemos nuestra salida familiar de un modelo de regresión lineal. Sin embargo, tenga en cuenta que si existe una correlación en serie en las perturbaciones, estas estimaciones de los errores estándar son incorrectas:

```
Llamada:
lm (fórmula = Energía ~ rmn1173 + grf0175 + grf575 + jec477 +
    jec1177 +
    jec479 + embargo + rehenes + oilc
    Desempleo
    datos = pres.energy)
+ Aprobación +
```

Derechos residuales de autor:

Min	1T	Mediana	3T	Max
- 104,995 -12,921		- 3.448	8.973 111.744	

Coeficientes:

	Estimar	Std.	Valor t de error	Pr (> t)
(Intercepción)	319.7442	46.8358	6,827	1,51e-10 ***
rmn1173	78.8261	28.8012	2,737	0,00687 **
grf0175	60.7905	26.7006	2,277	0,02406 *
grf575	- 4.2676	26.5315	- 0,161	0,87240
jec477	47.0388	26.6760	1,763	0,07966.
jec1177	15.4427	26.3786	0.585	0.55905
jec479	72.0519	26.5027	2,719	0,00724 **
embargo	96,3760	13.3105	7.241	1.53e-11 ***
rehenes	- 4.5289	7.3945	- 0,612	0,54106
oilc	- 5.8765	1.0848	- 5.417	2.07e-07 ***
Aprobación	- 1.0693	0.2147	- 4.980	1.57e-06 ***
Desempleo	- 3.7018	1.3861	- 2.671	0.00831 **

Signif. códigos:	0 ***	0,001 **	0,01 *	0,05. 0,1
				1

Error estándar residual: 26,26 en 168 grados de libertad

Múltiples R-cuadrado: 0,5923, R cuadrado ajustado: 0.5656

Estadístico F: 22,19 en 11 y <2,2e-16 168 DF, valor p:

Sin embargo, necesitamos diagnosticar si la correlación serial está presente en el antes de contentarnos con los resultados. Para hacer esto, necesitamos cargar `lmtest` paquete (introducido por primera vez en el Cap. 6) para que algunos diagnósticos estén disponibles. Al cargar este paquete, podemos calcular una prueba de Durbin-Watson o Breusch-Godfrey para la autocorrelación:

```
biblioteca (lmtest)
dwtest (static.ols)
bgtest (static.ols)
```

Tanto para el `dwtest` y `bgtest` comandos, simplemente proporcionamos el nombre del modelo como argumento principal. La Durbin-Watson **prueba** (calculado con `dwtest`)

prueba la correlación serial de primer orden y no es válido para un modelo que incluye una variable dependiente rezagada. Nuestra prueba produce el siguiente resultado:

Prueba de Durbin-Watson

datos: static.ols

DW = 1,1649, valor $p = 1,313e-09$

hipótesis alternativa: la verdadera autocorrelación es mayor de 0

El Durbin – Watson D estadística (1.1649 en este caso), no tiene una distribución paramétrica. Tradicionalmente el valor de D se ha comparado con tablas basadas en los resultados de Monte Carlo para determinar su importancia. R, sin embargo, proporciona una aproximación *pag*-valor con la estadística. Para una prueba de Durbin-Watson, la hipótesis nula es que no hay autocorrelación, por lo que nuestro valor significativo de D sugiere que la autocorrelación es un problema.

Mientras tanto, los resultados de nuestro **Breusch-GRAMOdfrey prueba** (calculado con `bgtest`) ofrecen una conclusión similar. La prueba de Breusch-Godfrey tiene una distribución y se puede utilizar para probar la autocorrelación en un modelo con una variable dependiente rezagada. Por defecto, `elbgtest` El comando comprueba la correlación serial de primer orden, aunque la correlación serial de orden superior se puede probar con el pedido opción. Nuestro resultado en este caso es:

Prueba de Breusch-Godfrey para la correlación serial de ordenar hasta

1

datos: static.ols

Prueba LM = 38.6394, $gl = 1$, valor $p = 5.098e-10$

Nuevamente, la hipótesis nula es que no hay autocorrelación, por lo que nuestra significativa 2 El valor muestra que la correlación serial es una preocupación, y debemos hacer algo para dar cuenta de esto.

En este punto, podemos sacar una de dos conclusiones: La primera posibilidad es que nuestro *especificación del modelo estático* es correcta y necesitamos encontrar un estimador que sea eficiente en presencia de autocorrelación de errores. La segunda posibilidad es que hemos pasado por alto un efecto dinámico y necesitamos volver a especificar nuestro modelo. (En otras palabras, si hay un verdadero efecto de desbordamiento y no lo hemos modelado, entonces los errores parecerán estar correlacionados en serie). Consideraremos cada posibilidad.

Primero, si estamos seguros de que nuestra especificación estática es correcta, entonces nuestra forma funcional es correcta, pero según el teorema de Gauss-Markov, OLS es ineficaz con la autocorrelación de errores y los errores estándar están sesgados. Como alternativa, podemos utilizar mínimos cuadrados generalizados factibles (FGLS), que estima el nivel de correlación del error y lo incorpora al estimador. Aquí hay una variedad de técnicas de estimación, incluidos los estimadores de Prais-Winsten y Cochrane-Orcutt. Procedemos ilustrando el estimador Cochrane-Orcutt, aunque los usuarios deben tener cuidado

de los supuestos del modelo.⁹ En breve, **Cochrane-Orcutt** vuelve a estimar el modelo varias veces, actualizando la estimación de la autocorrelación del error cada vez, hasta que converge a una estimación estable de la correlación. Para implementar este procedimiento en R, necesitamos instalar y luego cargar el `orcutt` paquete:

```
biblioteca install.packages("orcutt")
(orcutt)
cochrane.orcutt (static.ols)
```

Una vez que hayamos cargado este paquete, insertamos el nombre de un modelo lineal que hemos estimado con OLS en el `cochrane.orcutt` mando. Esto luego vuelve a estimar iterativamente el modelo y produce nuestros resultados FGLS de la siguiente manera:

\$ Cochrane.Orcutt

Llamada:
lm (fórmula = YB ~ XB - 1)

Derechos residuales de autor:

Min	1T	Mediana	3T	Max
- 58.404 -9.352		- 3.658	8.451	100.524

Coefficientes:

	Estimar	Std.	Valor t de error	Pr (> t)
XB (intercepción)	16.8306	55.2297	0.305	0,7609
XBrmn1173	91.3691	15.6119	5.853	2.5e-08 ***
XBgrf0175	32.2003	16.0153	2.011	0.0460 *
XBgrf575	- 7,9916	15.7288	- 0,508	0,6121
XBjec477	29.6881	15.6159	1.901	0.0590.
XBjec1177	- 6.4608	15.6174	- 0,414	0,6796
XBjec479	- 20.0677	15.6705	- 1.281	0,2021
XBembargo	34.5797	15.0877	2.292	0.0232 *
XBhostages	- 16,9183	14.1135	- 1,199	0.2323
XBoilc	0.8240	1.0328	0,798	0.4261
Aprobación XBA	- 0,2399	0.2742	- 0,875	0.3829
XBUemploy	- 0.1332	4.3786	- 0.030	0.9758

Signif. códigos: 0 *** 0,001 ** 0,01 * 0,05 . 0,1 1

Error estándar residual: 20,19 en 167 grados de libertad

⁹En particular, en cada etapa del proceso iterativo, el modelo lineal se estima regresando y_t D y_t y_{t-1} en X_t D X_t X_{t-1} (Hamilton 1994, pag. 223). Este procedimiento asume que el El proceso de ajuste dinámico es el mismo para las variables de resultado y de entrada, lo cual es poco probable. Por tanto, una especificación dinámica como un modelo de rezago distributivo autorregresivo sería más flexible.

Múltiple R cuadrado: 0,2966,
0.2461

R cuadrado ajustado:

Estadística F: 5.87 en 12 y 167 DF,
1.858e-08

valor p:

\$ rho

[1] 0,8247688

\$ number.interaction

[1] 15

La primera parte de la tabla se parece a la salida de regresión lineal familiar (aunque las letras XB aparecen antes del nombre de cada predictor). Todos estos coeficientes, errores estándar y estadísticas inferenciales tienen exactamente la misma interpretación que en un modelo estimado con MCO, pero nuestras estimaciones ahora deberían ser eficientes porque se calcularon con FGLS. Cerca de la parte inferior de la salida, vemos \$rho, lo que nos muestra nuestra estimación final de la autocorrelación de errores. También vemos \$numero.interacción, lo que nos informa que el modelo fue reestimado en 15 iteraciones antes de que convergiera al resultado final. FGLS está diseñado para producir estimaciones eficientes si una especificación estática es correcta.

Por el contrario, si creemos *especi fi cación dinámica* es correcta, tenemos que trabajar para volver a especificar nuestro modelo lineal para capturar esa forma funcional. De hecho, si obtenemos la forma funcional incorrecta, nuestros resultados están sesgados, por lo que es fundamental hacerlo bien. Agregar una especificación de retraso a nuestro modelo puede ser considerablemente más fácil si instalamos y cargamos el din paquete. Nombramos nuestro modelokoyck.ols por razones que serán evidentes en breve:

```
install.packages("dyn")
biblioteca (dyn)
pres.energy <-ts (pres.energy) koyck.ols <-dyn $ lm (Energy ~ lag
(Energy, -1) + rmn1173 +
grf0175 + grf575 + jec477 + jec1177 + jec479 + embargo + rehenes +
oilc + Aprobación + Desempleo, datos = energía pres.)
```

Después de cargar din, la segunda línea usa el ts comando para declarar que nuestros datos son datos de series de tiempo. En la tercera línea, observe que cambiamos el comando del modelo lineal para leer, dyn \$ lm. Esta modificación nos permite incluir variables rezagadas dentro de nuestro modelo. En particular, ahora hemos agregadolag (Energía, -1), que es el valor rezagado de nuestra variable dependiente. Con elretraso comando, especificamos la variable que se retrasa y cuántas veces se retrasa. Especificando -1, estamos mirando el valor inmediatamente anterior. (Los valores positivos representan valores futuros). El retraso predeterminado es 0, que solo devuelve los valores actuales.

Podemos ver los resultados de este modelo escribiendo [resumen \(koyck.ols\)](#):

Llamada:

```
lm (fórmula = dyn (Energía ~ retraso (Energía, -1) + rmn1173 +
grf0175 +
```


grf575 + jec477 + jec1177 + jec479 + embargo +
 rehenes +
 oilc + Aprobación + Desempleo), datos = energía pres.)

Derechos residuales de autor:

Min	1T	Mediana	3T	Max
- 51.282 -8.638		- 1.825	7.085 70.472	

Coeficientes:

	Estimar	Std.	Valor t	de error	Pr (> t)
(Interceptar)	62,11485	36,96818	1,680	0,09479.	
lag (Energía, -1)	0,73923	0,05113	14,458	<2e-16	***
rmn1173	171.62701	20.14847	8.518	9.39e-15	***
grf0175	51,70224	17,72677	2,917	0,00403	**
grf575	7.05534	17.61928	0.400	0.68935	
jec477	39.01949	17.70976	2.203	0.02895	*
jec1177	- 10,78300	17,59184	-0,613	0,54075	
jec479	28,68463	17,83063	1,609	0,10958	
embargo	10,54061	10,61288	0,993	0,32206	
rehenes	- 2.51412	4.91156	-0.512	0.60942	
oilc	- 1,14171	0,81415	-1,402	0,16268	
Aprobación	- 0,15438	0,15566	-0,992	0,32278	
Desempleo	- 0,88655	0,96781	-0,916	0,36098	

Signif. códigos: 0 *** 0,001 ** 0,01 * 0,05. 0,1 1

Error estándar residual: 17,42 en 166 grados de libertad

(2 observaciones eliminadas debido a R- a la falta)

cuadrado múltiple: 0,822, R cuadrado ajustado: 0,8092

Estadístico F: 63,89 en 12 y 166 DF, <2,2e-16 valor p:

Nuestra especificación aquí a menudo se denomina modelo de Koyck. Esto se debe a que Koyck (1954) observó que cuando se incluye una variable dependiente rezagada como predictor, cada predictor tendrá efectos de desbordamiento en los meses siguientes.

Considere dos ejemplos de efectos de desbordamiento de predictores. Primero, nuestro coeficiente para el habla de Nixon es aproximadamente 172. Aquí, estamos interesados en una *efecto impulso* donde el predictor aumentó a 1 en el mes en que se pronunció el discurso, y luego volvió a 0. Por lo tanto, en el mes de noviembre de 1973 cuando se pronunció el discurso, el efecto esperado de este discurso manteniendo todo lo demás igual es un aumento de 172 historias. en cobertura de pólizas energéticas. Sin embargo, en diciembre de 1973, el nivel de cobertura de noviembre es un predictor, y la cobertura de noviembre fue moldeada por el discurso. Dado que nuestro coeficiente de la variable dependiente rezagada es aproximadamente 0,74, y dado que 0:74 \times 172. Por lo tanto, esperamos que el discurso aumente la energía. cobertura en diciembre por 128, *ceteris paribus*. Sin embargo, el efecto también persistiría en enero porque el valor de diciembre predice el valor de enero de 1974. Desde

0:74 0:74 172 94, esperamos que el efecto del discurso de Nixon sea un 94 aumento de la historia en la cobertura de energía en enero, *ceteris paribus*. Este tipo de efecto dinámico decadente persiste para un efecto de impulso en cualquiera de estas variables, por lo que esta es una forma poderosa de especificar un modelo dinámico. Además, tenga en cuenta que un investigador podría trazar fácilmente estos efectos de la intervención en descomposición a lo largo del tiempo para visualizar el impacto dinámico de una intervención. Dicho gráfico es válido para un modelo de Koyck y se parecería al resultado de la Fig.9.3.

En segundo lugar, considere el efecto del desempleo. No debemos darle mucha importancia al impacto de este predictor porque el coeficiente no es discernible, pero sirve como ejemplo de interpretación del efecto dinámico de un predictor continuo. Si estamos interesados en un efecto de paso, nos gustaría saber cuál sería el impacto a largo plazo si un predictor aumentara en una sola unidad y se mantuviera en ese nivel más alto. Entonces, aunque no es estadísticamente discernible, el coeficiente de desempleo es 0:89, lo que significa que un aumento de un punto porcentual en el desempleo disminuye la atención de las noticias a la política energética en casi nueve décimas partes de una historia, en el mismo mes, en promedio, y *ceteris paribus*. Pero si el desempleo se mantuviera un punto porcentual más alto, ¿cómo cambio de cobertura a largo plazo? Si γ_{13} es el coeficiente de desempleo y γ_2 es el coeficiente de la variable dependiente rezagada, entonces el efecto a largo plazo es calculado por (Keele y Kelly 2006, pag. 189):

$$\frac{\gamma_{13}}{1 - \gamma_2} \quad (9,2)$$

Podemos calcular esto en R simplemente haciendo referencia a nuestros coeficientes:

```
koyck.ols $ coeficientes [13] / (1 - koyck.ols $ coeficientes [2])
```

Nuestra salida es 3: 399746, lo que significa que un aumento persistente del 1% en desempleo reduciría la cobertura de noticias de televisión de la política energética a largo plazo al 3.4 historias en promedio y todo lo demás igual. Nuevamente, este tipo de efecto a largo plazo podría ocurrir para cualquier variable que no se limite a una entrada de pulso.

Como estrategia final, podríamos incluir uno o más rezagos de uno o más predictores sin incluir una variable dependiente rezagada. En este caso, cualquier derrame se limitará a lo que incorporemos directamente en la especificación del modelo. Por ejemplo, si solo quisiéramos un efecto dinámico del habla de Nixon y una especificación estática para todo lo demás, podríamos especificar este modelo:

```
udl.mod <- dyn $ lm (Energía ~ rmn1173 + retardo (rmn1173, -1) +
  retraso (rmn1173, -2) + retraso (rmn1173, -3) + retraso (rmn1173, -4) +
  grf0175 + grf575 + jec477 + jec1177 + jec479 + embargo + rehenes +
  oilc + Aprobación + Desempleo, datos = energía pres.)
```

En esta situación, hemos incluido el valor actual del indicador de habla de Nixon, así como cuatro rezagos. Para una intervención, eso significa que este predictor tendrá efecto en noviembre de 1973 y durante 4 meses después. (En abril de 1974, sin embargo, el efecto cae abruptamente a 0, donde permanece). Vemos los resultados de este modelo escribiendo `resumen (udl.mod)`:

Llamada:

lm (fórmula = dyn (Energía ~ rmn1173 + retraso (rmn1173, -1) + retraso (rmn1173, -2) + retraso (rmn1173, -3) + retraso (rmn1173, -4) + grf0175 + grf575 + jec477 + jec1177 + jec479 + embargo + rehenes + petróleo + Aprobación + Desempleo), datos = energía pres.)

Derechos residuales de autor:

Min	1T	Mediana	3T	Max
- 43.654 -13.236		- 2.931	7.033	111.035

Coefficientes:

	Estimar	Std.	Valor t	de error	Pr (> t)
(Interceptar)	334.9988		44.2887		7.564 2.89e-12 ***
rmn1173	184.3602		34.1463		5.399 2.38e-07 ***
lag (rmn1173, -1)	181.1571	lag	34.1308		5.308 3.65e-07 ***
(rmn1173, -2)	154.0519	lag	34.2151		4.502 1.29e-05 ***
(rmn1173, -3)	115.6949		34.1447		3.388 0.000885 ***
retraso (rmn1173, -4)	75.1312		34.1391		2,201 0,029187 *
grf0175	60.5376		24.5440		2,466 0,014699 *
grf575	- 3.4512		24.3845		- 0,142 0,887629
jec477	45.5446		24.5256		1.857 0.065146.
jec1177	14.5728		24.2440		0,601 0,548633
jec479	71.0933		24.3605		2,918 0,004026 **
embargo	- 9.7692		24.7696		- 0,394 0,693808
rehenes	- 4.8323		6.8007		- 0,711 0,478392
oilc	- 6.1930		1.0232		- 6.053 9.78e-09 ***
Aprobación	- 1.0341		0.1983		- 5.216 5.58e-07 ***
Desempleo	- 4.4445		1.3326		- 3.335 0.001060 **

Signif. códigos:	0	***	0,001	**	0,01 *
				0,05.	0,1
					1

Error estándar residual: 24,13 sobre 160 grados de libertad

(Se eliminaron 8 observaciones por falta de información) R

cuadrado múltiple: 0,6683, R cuadrado ajustado: 0,6372

Estadístico F: 21,49 en 15 y 160 DF, valor de p: <2,2e-16

Como era de esperar, el efecto se reduce cada mes después del inicio. Para este modelo de rezago distribuido sin restricciones, tenemos que estimar varios parámetros más de los que requiere el modelo de Koyck, pero en algunos casos puede tener sentido teóricamente.

9.3 Autorregresión vectorial

El enfoque final que describiremos en este capítulo es la autorregresión vectorial (VAR). El enfoque VAR es útil cuando se estudian varias variables que son endógenas entre sí porque existe una causalidad recíproca entre ellas. La

El marco básico es estimar un modelo de regresión lineal para cada una de las variables endógenas. En cada modelo lineal, incluya varios valores rezagados de la propia variable de resultado (digamos *pag* rezagos de la variable) así como *pag* rezagos de todas las demás variables endógenas. Entonces, para el caso simple de dos variables endógenas, X_t y y_t , en el que establecemos nuestra longitud de retraso en *pag* D 3, estimaríamos dos ecuaciones que podrían representarse de la siguiente manera:

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \alpha_3 y_{t-3} + \alpha_4 X_{t-1} + \alpha_5 X_{t-2} + \alpha_6 X_{t-3} + \epsilon_t \quad (9.3)$$

$$X_t = \beta_0 + \beta_1 X_{t-1} + \beta_2 X_{t-2} + \beta_3 X_{t-3} + \beta_4 y_{t-1} + \beta_5 y_{t-2} + \beta_6 y_{t-3} + \epsilon_t$$

Un tratamiento más completo de esta metodología, incluida la notación para modelos con variables más endógenas y ejemplos de modelos que también incluyen variables exógenas, se puede encontrar en Brandt y Williams (2007). Con este modelo, se pueden utilizar pruebas como las de causalidad de Granger para evaluar si existe un efecto causal de una variable endógena a otra (Granger 1969).

Como ejemplo de cómo implementar un modelo VAR en R, pasamos al trabajo de Brandt y Freeman (2006), quienes analizan datos semanales sobre el conflicto israelo-palestino. Sus datos se extraen del Kansas Event Data System, que codifica automáticamente los informes de noticias en inglés para medir los eventos políticos, con el objetivo de utilizar esta información como una advertencia temprana para predecir cambios políticos. Las variables endógenas en estos datos son acciones políticas escaladas tomadas por EE.UU., Israel o Palestina, y dirigidas a uno de los otros actores. Esto produce seis variables **a2i**, **a2p**, **i2a**, **p2a**, **i2p**, y **p2i**. Las abreviaturas son "a" para estadounidense, "i" para israelí y "p" para palestino. Como ejemplo, **i2p** mide el valor escalado de las acciones israelíes dirigidas a los palestinos. Los datos semanales que usaremos van desde el 15 de abril de 1979 al 26 de octubre de 2003, por un total de 1278 semanas.

Para continuar, necesitamos instalar y cargar el `vars` paquete para que los comandos de estimación relevantes estén disponibles. También necesitamos el `extranjerio` paquete porque nuestros datos están en formato Stata:¹⁰

```
install.packages("vars") biblioteca
(vars)
biblioteca (extranjerio)
levant.0 <- read.dta ("levant.dta") levant <-
subconjunto (levant.0,
  select = c ("a2i", "a2p", "i2p", "i2a", "p2i", "p2a"))
```

Después de cargar los paquetes, cargamos nuestros datos en la tercera línea, nombrándola `levant.0`. Estos datos también contienen tres índices relacionados con la fecha, por lo que, para fines de análisis, en realidad necesitamos crear una segunda copia de los datos que solo incluya nuestras seis variables endógenas sin los índices. Hacemos esto usando el `subconjunto` comando para crear el conjunto de datos llamado `Levante`.

Un paso clave en este punto es elegir la longitud de retraso adecuada, *pag*. La longitud del retraso debe capturar todos los procesos de error y la dinámica causal. Un enfoque para

¹⁰Este ejemplo requiere el archivo `levant.dta`. Descargue este archivo de Dataverse (consulte la página vii) o el contenido en línea de este capítulo (consulte la página 155).

Determinar la longitud de retardo apropiada es ajustar varios modelos, elegir el modelo con el mejor ajuste y luego ver si los residuales muestran alguna evidencia de correlación serial. El comando `VARselect` estima automáticamente varios **vector autormodelos** de **regresión y Selecciones** qué longitud de retardo tiene el mejor ajuste. Dado que nuestros datos son semanales, consideramos retrasos de hasta 104 semanas, o datos de 2 años, para considerar todas las opciones posibles. El siguiente comando puede tardar un minuto en ejecutarse porque 104 modelos están siendo estimado:

```
levant.select <-VARselect (levant, type = "const", lag.max = 104)
```

Para averiguar cuál de las longitudes de retraso se ajusta mejor, podemos **tipo** `levant.select $` **selección**. Nuestro resultado es simplemente el siguiente:

AIC (n)	HQ (n)	SC (n)	FPE (n)
60	4	1	47

Esto informa la longitud de retraso elegida para el criterio de información de Akaike, el criterio de información de Hannan-Quinn, el criterio de Schwarz y el error de predicción de pronóstico. Los cuatro índices están codificados para que los valores más bajos sean mejores. Para contrastar los extremos, el valor más bajo del criterio de Schwarz, que tiene una fuerte penalización por parámetros adicionales, es para el modelo con solo un rezago de las variables endógenas. Por el contrario, el mejor ajuste en el AIC proviene del modelo que requiere 60 rezagos, lo que quizás indique que existe una estacionalidad anual. Se puede ver una impresión mucho más larga con el valor de cada uno de los cuatro índices de ajuste para los 104 modelos escribiendo: `levant.select $ criterios`. Idealmente, nuestros índices de ajuste se habrían establecido en modelos con longitudes de retardo similares. Como no lo hicieron, y dado que tenemos 1278 observaciones, tomaremos la ruta más segura con el largo retraso sugerido por la AIC.¹¹

Para estimar el **vector autormodelo** de **egresión** con *pag* D 60 rezagos de cada variable endógena, escribimos:

```
levant.AIC <-VAR (levant, tipo = "const", p = 60)
```

La VAR El comando requiere el nombre de un conjunto de datos que contiene todas las variables endógenas. Con el tipo opción, hemos elegido "const " en este caso (el predeterminado). Esto significa que cada uno de nuestros modelos lineales incluye una constante. (Otras opciones incluyen especificar un "tendencia, "" ambos " una constante y una tendencia, o "ninguno" que no incluye ninguno.) Con la opción *pag* Elegimos la longitud del retraso. Una opción que no usamos aquí es la **exógeno** opción, que nos permite especificar variables exógenas.

Una vez que hayamos estimado nuestro modelo usando VAR, lo siguiente que debemos hacer es diagnosticar el modelo mediante una llamada especial al gráfico función:

```
parcela (levant.AIC, lag.acf = 104, lag.pacf = 104)
```

Usando el nombre de nuestro modelo VAR, `levant.AIC`, como el único argumento en gráfico, R proporcionará automáticamente un gráfico de diagnóstico para cada uno de los endógenos

¹¹Se le anima a examinar los modelos que habrían sido elegidos por el criterio de Hannan-Quinn (4 rezagos) o el criterio de Schwarz (1 rezago) por su cuenta. ¿Cómo funcionan estos modelos en términos de diagnóstico? ¿Cómo cambiarían las inferencias?

variables. Con las opciones `delag.acf` y `lag.pacf`, especificamos que las gráficas de ACF y PACF que los informes de este comando deben mostrarnos el valor de 2 años (104 semanas) de patrones de autocorrelación. Para nuestros datos, R produce seis parcelas. R muestra estos gráficos uno a la vez, y entre cada uno, la consola presentará el siguiente mensaje:

Presione <Return> para ver la siguiente trama:

R mantendrá una trama en el visor hasta que presione el botón Regreso, en cuyo punto pasa al siguiente gráfico. Este proceso se repite hasta que se muestra el gráfico de cada resultado.

Alternativamente, si quisiéramos ver la gráfica de diagnóstico para una variable endógena en particular, podríamos escribir:

```
plot(levant.AIC, lag.acf = 104, lag.pacf = 104, names = "i2p")
```

Aquí el nombre La opción nos ha permitido especificar que queremos ver los diagnósticos de **i2p** (Acciones israelíes dirigidas hacia Palestina). El gráfico de diagnóstico resultante se muestra en la Fig. 9.5. El gráfico tiene cuatro partes: En la parte superior hay un gráfico de líneas que muestra los valores verdaderos en una línea negra sólida y los valores ajustados en una línea discontinua azul. Directamente debajo de esto hay un gráfico lineal de los residuos contra una línea en cero. Estos dos primeros gráficos pueden ilustrar si el modelo hace predicciones insesgadas del resultado de manera consistente y si los residuos son homocedásticos a lo largo del tiempo. En general, los pronósticos se sitúan constantemente alrededor de cero, aunque en las últimas 200 observaciones la varianza del error parece aumentar ligeramente. El tercer gráfico, en la parte inferior izquierda, es el ACF para los residuos en **i2p**.¹² Por último, en la parte inferior derecha del panel, vemos el PACF para **i2p** Residuos de. Ningún pico es significativo en el ACF y solo un pico es significativo en el PACF durante 2 años, por lo que concluimos que nuestra estructura de rezagos ha filtrado suficientemente cualquier correlación serial en esta variable.

Al interpretar un modelo VAR, recurrimos a dos herramientas para extraer inferencias e interpretaciones de estos modelos. Primero, usamos la prueba de causalidad de Granger para determinar si una variable endógena causa las otras. Esta prueba es simplemente un bloque *F*-prueba de si todos los rezagos de una variable pueden excluirse del modelo. Para una prueba conjunta de si una variable afecta a las otras variables en el sistema, podemos usar la causalidad mando. Por ejemplo, si quisiéramos probar si las acciones israelíes hacia Palestina causaron acciones de las otras cinco diadas dirigidas, escribiríamos:

```
causalidad(levant.AIC, cause = "i2p") $ Granger
```

El comando aquí pide el nombre del modelo primero (`levant.AIC`), y luego con el `cause` opción, especificamos cuál de las variables endógenas deseamos probar el efecto. Nuestro resultado es el siguiente:

¹²Tenga en cuenta que, de forma predeterminada, el gráfico R presenta en realidad incluye la correlación perfecta de retraso cero. Si desea eliminar eso, dada nuestra gran longitud de retraso y el tamaño del panel, simplemente cargue el TSA paquete antes de dibujar el gráfico para cambiar el valor predeterminado.




Figura 9.5 Valores predichos, función de autocorrelación residual y autocorrelación parcial residual función para la serie de Israel a Palestina en un modelo de autorregresión vectorial de seis variables

Causalidad Granger H_0 : $i2p$ no causa Granger

$a2i$ $a2p$ $i2a$

$p2i$ $p2a$

datos: VAR objeto levant.AIC

Prueba $F = 2.1669$, $gl1 = 300$, $gl2 = 5142$, valor $p < 2.2e-16$

La hipótesis nula es que los coeficientes para todos los rezagos de **$i2p$** son cero al modelar cada una de las otras cinco variables de resultado. Sin embargo, nuestro F -prueba es significativa aquí, ya que la minúscula *pag*-muestra el valor. Por lo tanto, concluiríamos que las acciones israelíes dirigidas hacia Palestina tienen un efecto causal sobre las otras variables de acción política en el sistema.

Podemos proceder a probar si cada una de las otras cinco variables de Granger- causa los otros predictores en el sistema al considerar cada una con el causalidad mando:

```
causalidad (levant.AIC, causa = "a2i") $ causalidad de
Granger (levant.AIC, causa = "a2p") $ causalidad de Granger
(levant.AIC, causa = "i2a") $ causalidad de Granger
(levant.AIC, causa = "p2i") $ Causalidad de Granger
(levant.AIC, cause = "p2a") $ Granger
```

Los resultados no se reproducen aquí para preservar el espacio. Sin embargo, en el nivel de confianza del 95%, verá que cada variable causa de manera significativa a las demás, a excepción de las acciones estadounidenses dirigidas hacia Israel (**a2i**).

Finalmente, para tener una idea del impacto sustantivo de cada predictor, recurrimos al análisis de respuesta al impulso. La lógica aquí es algo similar al análisis de intervención que graficamos en la Fig.9.3. Una función de respuesta al impulso considera un aumento de una unidad en una de las variables endógenas y calcula cómo tal choque exógeno influiría dinámicamente en todas las variables endógenas, dados los patrones de autorregresión y dependencia.

Al interpretar una función de impulso-respuesta, una consideración clave es el hecho de que los choques a una variable endógena casi siempre están correlacionados con los choques a otras variables. Por lo tanto, debemos considerar que es probable que un choque de una unidad en el término residual de una variable cree un movimiento contemporáneo en los residuos de las otras variables. Los términos fuera de la diagonal de la matriz de varianza-covarianza de los residuos de las variables endógenas, $\hat{\Omega}$, nos dice cuánto covarían los choques.

Hay varias formas de abordar este problema. Uno es usar la teoría para determinar el orden de las variables endógenas. En este enfoque, el investigador asume que un choque en una variable endógena no se ve afectado por choques en ninguna otra variable. Entonces, los shocks de una segunda variable se ven afectados solo por los de la primera variable y no por los demás. El investigador repite de forma recursiva este proceso para identificar un sistema en el que todas las variables se pueden ordenar en una cadena causal. Con un sistema diseñado teóricamente como este, el investigador puede determinar cómo los choques contemporáneos se afectan entre sí con una descomposición estructurada de Cholesky de $\hat{\Omega}$ (Enders 2009, pag. 309).

Una segunda opción, que es la opción predeterminada en R's `irf` comando, es asumir que no existe un conocimiento teórico del orden causal de los choques contemporáneos y aplicar el método de *ortogonalización de los residuos*. Esto involucra otra descomposición de Cholesky, en la que encontramos \mathbf{A}_1 resolviendo $\mathbf{A}_1 \mathbf{A}_0 \mathbf{D} = \hat{\Omega}$. Para obtener más detalles sobre el orden de respuesta o la ortogonalización de residuos, consulte Brandt y Williams (2007, págs. 36-41 y 66-70), Enders (2009, págs. 307-315) o Hamilton (1994, págs. 318-324).

Como ejemplo de una función de respuesta al impulso, graficaremos el efecto de un evento político adicional de Israel dirigido hacia Palestina. R calculará nuestro **Impulse r responder Función** con el `irf` comando, utilizando la ortogonalización predeterminada de residuos. Una de las opciones clave de este comando es `botacorreas`, que determina si construir un intervalo de confianza con **botacorreas**. Generalmente, es aconsejable informar la incertidumbre en las predicciones, pero el proceso puede tomar varios

minutos.¹³ Entonces, si el lector quiere un resultado rápido, configure `boot = FALSE`. Para obtener el resultado con intervalos de confianza, escriba:

```
levant.irf <- irf(levant.AIC, impulso = "i2p", n.ahead = 12, boot = TRUE)
```

Nombramos nuestra función de respuesta al impulso `levant.irf`. El comando requiere que digamos el nombre de nuestro modelo (`levant.AIC`). La opción `impulso` nos pide que nombremos la variable de la que queremos el efecto, el `n. cabeza`. La opción `establece` con qué anticipación deseamos pronosticar (decimos 12 semanas o 3 meses) y, por último, `bota` determina si se deben crear intervalos de confianza basados en una muestra de arranque.

Una vez que hayamos calculado esto, podemos graficar la función de respuesta al impulso con una llamada especial a gráfico:

```
parcela(levant.irf)
```

El gráfico resultante se muestra en la Fig. 9.6. Hay seis paneles, uno para cada una de las seis variables endógenas. El eje vertical de cada panel enumera el nombre de la variable endógena y representa el cambio esperado en esa variable. El eje horizontal de cada panel representa el número de meses que han transcurrido desde el choque. Cada panel muestra una línea roja sólida en cero, que representa dónde cae un no efecto en el gráfico. La línea negra continua representa el efecto esperado en cada mes y las líneas discontinuas rojas representan cada intervalo de confianza. Como muestra la figura, el impacto real de un impacto en las acciones de Israel a Palestina es dramático para la propia serie Israel a Palestina (**i2p**) debido a la autorregresión y la retroalimentación de los efectos a otras series. También vemos un salto significativo en las acciones de Palestina a Israel (**p2i**) durante los siguientes 3 meses. Con las otras cuatro series, los efectos palidecen en comparación. Fácilmente podríamos producir gráficos similares a la Fig. 9.6 calculando la función de respuesta al impulso para una descarga en cada una de las seis entradas. Esto es generalmente un

bien idea, pero se omite aquí por espacio.

9.4 Lecturas adicionales sobre el análisis de series de tiempo

Con estas herramientas en la mano, el lector debe tener alguna idea de cómo estimar y interpretar modelos de series de tiempo en R utilizando tres enfoques: modelado de Box-Jenkins, modelado econométrico y autorregresión vectorial. Tenga en cuenta que, si bien este capítulo utiliza ejemplos simples, el análisis de series de tiempo generalmente es un desafío. Puede ser difícil encontrar un buen modelo que dé cuenta adecuadamente de todos los procesos de tendencia y error, pero el analista debe trabajar con cuidado a través de todos estos problemas o el problema.

¹³Tenga en cuenta que los intervalos de confianza basados en bootstrap no siempre brindan las coberturas correctas porque confunden la información sobre qué tan bien encaja el modelo con la incertidumbre de los parámetros. Por esta razón, los enfoques bayesianos suelen ser la mejor manera de representar la incertidumbre (Brandt y Freeman 2006; Sims y Zha 1999).




Figura 9.6 Función de respuesta al impulso para un choque de una unidad en el modelo de autorregresión de $i2p$ en un seis vector variable de la serie Israel-Palestina

las inferencias estarán sesgadas. (Vean de nuevo, Granger y Newbold1974.) Que así sea seguro de Reconozca que a menudo se necesitan varios intentos para encontrar un modelo que dé cuenta de todos los problemas.

También vale la pena tener en cuenta que este capítulo no puede abordar de manera integral ninguno de los tres enfoques que consideramos, y mucho menos abordar todos los tipos de análisis de series de tiempo. (El análisis espectral, el análisis de ondulitas, los modelos de espacio de estados y los modelos de corrección de errores son solo algunos de los temas que no se tratan aquí). Por lo tanto, se recomienda al lector interesado que consulte otros recursos para obtener más detalles importantes sobre varios temas en el modelado de series de tiempo. Buenos libros que cubren una variedad de temas de series de tiempo e incluyenR código son: Cowpertwait y Metcalfe (2009), Cryer y Chan (2008) y Shumway y Stoffer (2006). Para más profundidad en

la teoría detrás de las series de tiempo, buenos volúmenes de científicos políticos incluyen BoxSteffensmeier et al. (2014) y Brandt y Williams (2007). Otros buenos libros que cubren la teoría de series de tiempo incluyen: Box et al. (2008), Enders (2009), Wei (2006), Lütkepohl (2005), y para una versión avanzada, consulte Hamilton (1994). Varios libros se centran en temas específicos y en la aplicación de los métodos en R: Por ejemplo, Petris et al. (2009) cubre modelos lineales dinámicos, también llamados modelos de espacio de estado, y explica cómo utilizar los correspondientes dlm paquete en R para aplicar estos métodos. Pfaff (2008) analiza los modelos de datos cointegrados, como los modelos de corrección de errores y los modelos de corrección de errores vectoriales, utilizando la R paquete vars. Además, los lectores que estén interesados en modelos de sección transversal de series de tiempo o datos de panel, deben consultar el plm paquete, que facilita la estimación de modelos apropiados para esos métodos. Mientras tanto, Mátyás y Sevestre (2008) ofrece una base teórica sobre métodos de datos de panel.

9.5 Código de serie temporal alternativo

Como se menciona en la Secta. 9.1, ahora mostraremos una sintaxis alternativa para producir las Figs. 9.3 y 9.4. Este código es un poco más largo, pero es más generalizable.¹⁴ En primer lugar, si no tiene todos los paquetes, objetos de datos y modelos cargados antes, asegúrese de volver a cargar algunos de ellos para que podamos dibujar la figura:

```

biblioteca (TSA)
pres.energy <- read.csv ("PESEnergy.csv") predictores <- as.matrix (subconjunto
(pres.energy, select = c (rmn1173,
                        grf0175, grf575, jec477, jec1177, jec479, embargo, rehenes, oilc, aprobación,
                        desempleo)))

```

Las tres líneas de código anteriores se ejecutaron anteriormente en el capítulo. A modo de recordatorio, la primera línea carga elTSA paquete, el segundo carga nuestros datos de cobertura de la póliza de energía y el tercero crea una matriz de predictores.

Ahora, para volver a dibujar cualquiera de las dos figuras, debemos dedicarnos un poco a la gestión de datos:

```

meses <- 1: 180
predictores.estáticos <- predictores [, - 1] predictores.dinámicos <-
predictores [, 1, drop = FALSE]
y <- ts (energía pres. $ Energía, frecuencia = 12, inicio = c (1972, 1))

```

Primero, definimos un índice mensual, como antes. En segundo lugar, subconjuntamos nuestra matriz predictores a los que tienen un efecto estático. En tercer lugar, aislamos nuestro predictor dinámico del discurso de Nixon. Cuarto, usamos elts comando para declarar la cobertura de la póliza energética como un objeto de serie temporal. En esta última línea, usamos el frecuencia opción para especificar que estos son datos mensuales (de ahí el valor 12) y el comienzo opción tener en cuenta que estos datos comienzan en el primer mes de 1972.

¹⁴Mi agradecimiento a Dave Armstrong por escribir y sugerir este código alternativo.

A continuación, necesitamos estimar realmente nuestra función de transferencia. Una vez hecho esto, podemos guardar varias salidas del modelo:

```
dynamic.mod <- arimax(y, order = c(1,0,0), xreg = static.predictors,
  xtransf = predictores dinámicos, transferencia = lista(c(1,0)))
b <- coef(mod dinámico)
static.coefs <- b[match(colnames(static.predictors), names(b))]
ma.coefs <- b[grep("MA0", names(b))]
ar.coefs <- b[grep("AR1", nombres(b))]
```

La primera línea se ajusta a nuestra función de transferencia. El segundo usa el `coef` comando para extraer los coeficientes del modelo y guardarlos en un vector llamado `B`. Las últimas tres líneas separan nuestros coeficientes en efectos estáticos (`static.coefs`), efectos dinámicos iniciales (`ma.coefs`), y términos de decadencia (`ar.coefs`). En cada línea, hacemos referencia cuidadosamente a los nombres de nuestro vector de coeficientes, utilizando el partido comando para encontrar coeficientes para los predictores estáticos, y luego el `grep` comando para buscar términos que contengan `MA0` y `AR1`, respectivamente, al igual que los términos de salida de una función de transferencia.

Con todos estos elementos extraídos, ahora pasamos específicamente a volver a dibujar la Fig. 9.3, que muestra el efecto de la intervención del habla de Nixon contra los datos reales. Nuestro efecto de intervención consta de dos partes, el valor esperado de mantener todos los predictores estáticos en sus valores para el mes 58 y el efecto dinámico de la función de transferencia. Creamos esto de la siguiente manera:

```
xreg.pred <- b[["interceptar"]] + static.coefs %*% static.predictors[58,]
transf.pred <- as.numeric(dynamic.predictors %*% ma.coefs +
  ma.coefs * (ar.coefs ^ (meses-59)) * (meses > 59))
y.pred <- ts(xreg.pred + transf.pred, frecuencia = 12, inicio = c(1972,1))
```

La primera línea simplemente hace la predicción estática a partir de una ecuación lineal. El segundo usa nuestros efectos iniciales y términos de decaimiento para predecir el efecto dinámico de la intervención. En tercer lugar, sumamos las dos piezas y las guardamos como una serie de tiempo con la misma frecuencia y fecha de inicio que la serie original. Con ambos `y` y `y.pred` ahora codificado como series de tiempo de la misma frecuencia durante el mismo lapso de tiempo, ahora es fácil recrear la Fig. 9.3:

```
plot(y, xlab = "Month", ylab = "Energy Policy Stories", type = "l")
lines(y.pred, lty = 2, col = 'blue', lwd = 2)
```

La primera línea simplemente traza la serie de tiempo original y la segunda línea agrega el efecto de intervención en sí.

Con todo el trabajo de configuración que hemos realizado, reproduciendo la Fig. 9.4 ahora solo requiere tres líneas de código:

```
full.pred <- fitted(dynamic.mod)
plot(full.pred, ylab = "Energy Policy Stories", type = "l",
  ylim = c(0,225))
points(y, pch = 20)
```

La primera línea simplemente usa el `fitted` comando para extraer valores ajustados del modelo de función de transferencia. La segunda línea traza estos valores ajustados y la tercera suma los puntos que representan la serie original.

9.6 Problemas de práctica

Este conjunto de problemas de práctica revisa cada uno de los tres enfoques del modelado de series de tiempo presentados en el capítulo y luego plantea una pregunta adicional sobre los datos de energía de Peake y Eshbaugh-Soha que le pide que aprenda sobre un nuevo método. Las preguntas 1 a 3 se relacionan con modelos de una sola ecuación, por lo que todas estas preguntas utilizan un conjunto de datos sobre el consumo de electricidad en Japón. Mientras tanto, la pregunta n.º 4 utiliza datos económicos de EE. UU. Para un modelo de ecuaciones múltiples.

1. Visualización de series de tiempo: Wakiyama et al. (2014) estudian el consumo de electricidad en Japón, evaluando si el accidente nuclear de Fukushima del 11 de marzo de 2011 afectó el consumo de electricidad en varios sectores. Para ello, realizan un análisis de intervención sobre medidas mensuales de consumo eléctrico en megavatios (MW), de enero de 2008 a diciembre de 2012. Cargue el extranjero paquete y abra estos datos en formato Stata desde el archivo `comprehensiveJapanEnergy.dta`. Este archivo de datos está disponible en Dataverse (consulte la página vii) o en el contenido en línea de este capítulo (consulte la página 155). Nos centraremos en el consumo de electricidad de los hogares (nombre de la variable: **casa**). Tome el logaritmo de esta variable y trace una gráfica lineal del consumo de electricidad del hogar registrado de mes a mes. ¿Qué patrones son evidentes en estos datos?

2. Modelado de Box – Jenkins:

una. Trace la función de autocorrelación y la función de autocorrelación parcial para el consumo de electricidad doméstico registrado en Japón. ¿Cuáles son las características más evidentes de estas figuras?

B. Wakiyama y col. (2014) argumentan que un ARIMA (1,0,1), con un componente ARIMA de temporada (1,0,0) se ajusta a esta serie. Estime este modelo e informe sus resultados. (*Insinuación:* Para este modelo, querrá incluir la opción estacional = lista (orden = c (1,0,0), período = 12) en el arima mando.)

C. ¿Qué tan bien encaja este modelo ARIMA? ¿Cómo se ven el ACF y el PACF para los residuos de este modelo? ¿Cuál es el resultado de un Ljung-Box? Q -¿prueba?

D. Utilizar el `arimax` comando desde el TSA paquete. Estime un modelo que utiliza el proceso de error ARIMA de antes, los predictores estáticos de temperatura (**temperatura**) y temperatura al cuadrado (**temp2**), y una función de transferencia para la intervención de Fukushima (**tonto**).

mi. **Bono:** el indicador de Fukushima es en realidad un *paso* intervención, en lugar de una *legumbres*. Esto significa que el efecto *acumula* en vez de *decae*. Nota 8 describe cómo se acumulan estos efectos. Haga un dibujo del efecto acumulativo de la intervención de Fukushima en el consumo de electricidad de los hogares registrado.

3. Modelado econométrico:

una. Ajuste un modelo lineal estático utilizando OLS para el consumo de electricidad doméstico registrado en Japón. Usar temperatura (**temperatura**), temperatura al cuadrado (**temp2**), y el indicador de Fukushima (**tonto**) como predictores. Carga el `lmtest` paquete,

y calcular una prueba de Durbin-Watson y Breusch-Godfrey para este modelo lineal. ¿Qué conclusiones sacarías de cada uno? ¿Por qué crees que obtienes este resultado?

- B. Vuelva a estimar el modelo lineal estático de consumo eléctrico doméstico registrado utilizando FGLS con el algoritmo Cochrane-Orcutt. ¿Qué tan similares o diferentes son sus resultados de los resultados de OLS? ¿Por qué crees que es esto?
- C. Carga el *din* paquete y agregue una variable dependiente rezagada a este modelo. ¿Cuál de los tres modelos econométricos cree que es el más apropiado y por qué? ¿Cree que su modelo econométrico preferido o el análisis de intervención de Box-Jenkins es más apropiado? ¿Por qué?

4. Autorregresión vectorial:

una. Enders (2009, pag. 315) presenta datos trimestrales sobre la economía estadounidense, que va desde el segundo trimestre de 1959 hasta el primer trimestre de 2001. Cargue el *vars* y *extranjer* paquetes y luego abra los datos en formato Stata desde el archivo *moneyDem.dta*. Este archivo está disponible en Dataverse (consulte la página vii) o el contenido en línea de este capítulo (consulte la página 155). Subconjunto de los datos para incluir solo tres variables: cambio en el PIB real registrado (**drlrgdp**), cambio en la oferta monetaria real M2 (**dirm2**), y cambio en la tasa de interés a 3 meses de las letras del Tesoro de EE. UU. (**drs**). Utilizando la *VAR*seleccionar comando, determine la longitud de retardo de mejor ajuste para un modelo VAR de estas tres variables, de acuerdo con el AIC.

- B. Calcule el modelo que determinó que es el que mejor se ajusta según el AIC. Examine las gráficas de diagnóstico. ¿Cree que estas series están libres de correlación serial y que la forma funcional es correcta?
- C. Para cada una de las tres variables, pruebe si la variable Granger causa las otras dos.
- D. En política monetaria, la tasa de interés es una herramienta de política importante para el Banco de la Reserva Federal. Calcule una función de respuesta al impulso para un aumento de un punto porcentual en la tasa de interés (**drs**). Dibuje una gráfica de los cambios esperados en la oferta monetaria registrada (**dirm2**) y PIB real registrado (**drlrgdp**). (*Insinuación:* Incluir la opción *respuesta = c* ("**drlrgdp**", "**dirm2**") en el *irf* función.) Sea claro acerca de si está ortogonalizando los residuos o haciendo una suposición teórica sobre el orden de respuesta.

- 5. Bonificación: es posible que haya notado que Peake y Eshbaugh-Soha (2008) los datos sobre la cobertura televisiva mensual del tema energético se utilizaron como ejemplo para la regresión del recuento en el Cap. 7 y como ejemplo de serie temporal en este capítulo. Brandt y Williams (2001) desarrollan un modelo autorregresivo de Poisson (PAR) para los datos de recuento de series de tiempo, y Fogarty y Monogan (2014) aplican este modelo a estos datos de política energética. Replica este modelo PAR en estos datos. Para obtener información sobre la replicación, consulte: <http://hdl.handle.net/1902.1/16677>.